

湖仓推理参数矩阵

将模型选择、DeepSeek 质量、成本、稳定性和审计证据拆开比较。SQL 为可执行验证，Python 使用隐藏测试，故障分析以编码化根因与动作评分。

当前结论

默认本地推理选择 Qwen3.8-27B-FP8 + vLLM；本轮裁决后质量 100.0%，且显存占用 28.51 GiB，明显低于 Qwen3.6 的 34.23 GiB。复杂 SQL/Python 与故障分析按请求启用 reasoning_effort=low。DeepSeek 在线默认 low/32K；private 默认 high/256K，后者是 n=2 下的风险保守选择。

Qwen 选型：同一 RTX 4090，质量与耗时并列

仅比较同机、CPU offload=0 的两组推荐 thinking 配置。DeepSeek 不进入此处的延迟比较。

qwen3.8-27b-fp8

Qwen3.8 FP8 / low / 32K

100.0%

宏平均



18 题串行总耗时

qwen3.6-35b-a3b-fp8

Qwen3.6 FP8 / thinking / 28K

80.6%

宏平均



18 题串行总耗时

DeepSeek 质量：先分 endpoint，再比较思考档位

每格为对应能力的平均通过率；宏平均是三类能力等权平均。online 的动态 alias 与 private 固定 revision 不能解释为同模型 A/B。

endpoint
online-gateway
deepseek-v4-flash

思考档位	SQL	Python	故障分析	宏平均
low 32K cap · n=2	100.0%	83.3%	87.5%	90.3% +/- 2.0pp
high 256K cap · n=2	100.0%	83.3%	91.7%	91.7% +/- 3.9pp
max 384K cap · n=2	100.0%	91.7%	95.8%	95.8% +/- 2.0pp

endpoint
private-dgx-spark
deepseek-v4-flash-0731

思考档位	SQL	Python	故障分析	宏平均
low 32K cap · n=2	100.0%	66.7%	83.3%	83.3% +/- 0.0pp
high 256K cap · n=2	100.0%	83.3%	87.5%	90.3% +/- 2.0pp
max 384K cap · n=2	100.0%	83.3%	79.2%	87.5% +/- 9.8pp

DeepSeek 成本：耗时与输出 tokens 独立刻度

条形长度仅在同一指标内比较，不把时延、token 或正确率折叠成单一分数。

endpoint / 档位	18 题总耗时	输出 tokens	截断	空 final	HTTP/网络错误
online-gateway low · 32K · n=2	2m 05s	12,450	0.0	0.0	0.0
online-gateway high · 256K · n=2	18m 42s	123,031	0.0	0.5	0.0
online-gateway max · 384K · n=2	23m 52s	152,272	0.0	0.0	0.0
private-dgx-spark low · 32K · n=2	5m 07s	13,745	0.0	0.0	0.0
private-dgx-spark high · 256K · n=2	5m 03s	13,100	0.0	0.0	0.0

endpoint / 档位	18 题总耗时	输出 tokens	截断	空 final	HTTP/网络错误
private-dgx-spark max • 384K • n=2	5m 17s	14,023	0.0	0.0	0.0

重复稳定性：每个圆点是一轮宏平均

横轴为 0% 到 100%；这里显示随机采样的实际波动，而不是只显示均值。

endpoint / 档位	轮次位置	均值	标准差
online-gateway high • 256K		91.7%	+/- 3.9pp
online-gateway low • 32K		90.3%	+/- 2.0pp
online-gateway max • 384K		95.8%	+/- 2.0pp
private-dgx-spark high • 256K		90.3%	+/- 2.0pp
private-dgx-spark low • 32K		83.3%	+/- 0.0pp
private-dgx-spark max • 384K		87.5%	+/- 9.8pp

推理性能：首 token、端到端响应与解码吞吐分开看

统一短任务，1 次预热 + 3 次计量，SSE 单请求。TTFT 从请求发出到首个 reasoning/content delta；TPS 为 completion tokens / （响应时间 - TTFT）。输出长度不同，因此响应时间不能脱离 tokens 与 TPS 单独排名。

endpoint / 配置	TTFT 均值	响应时间均值	解码 TPS	输出 tokens	成功
online-gateway deepseek-v4-flash • deepseek-online-low	2.416s 1.860-2.765s	8.062s 7.675-8.816s	87.9 tokens/s	493	3/3 错误 0
private-dgx-spark deepseek-v4-flash-0731 • deepseek-private-high	0.252s 0.250-0.254s	13.499s 11.162-16.053s	35.5 tokens/s	470	3/3 错误 0
rtx4090-local qwen3.6-35b-a3b-fp8 • qwen36-thinking	0.087s 0.086-0.089s	17.095s 17.089-17.104s	112.2 tokens/s	1908	3/3 错误 0
rtx4090-local qwen3.8-27b-fp8 • qwen38-low	0.129s 0.124-0.134s	44.220s 44.212-44.227s	19.8 tokens/s	875	3/3 错误 0

模型冷启动：服务重启到 API ready

这是 Docker StartedAt 到 vLLM Application startup complete 的实测；未清 Linux page cache，不等于断电冷启动。外部 DeepSeek 服务生命周期不可观测。

模型	服务启动	模型加载	加载显存	开始时间 UTC
Qwen/Qwen3.8-27B-FP8	198.553s	150.598s	28.51 GiB	2026-08-17T05:52:02.598005847Z
Qwen/Qwen3.6-35B-A3B-FP8	211.675s	172.308s	34.23 GiB	2026-08-17T05:46:53.799435796Z

完整测试环境与部署配置

快照时间 2026-08-17T05:59:10.492507+00:00。敏感环境变量与 API 密钥未采集。

操作系统 / 内核 Ubuntu 24.04.4 LTS 7.0.0-28-generic	CPU Intel(R) Xeon(R) w5-3435X 1 socket • 16 cores/socket	内存 / Swap 30.6 GiB / 8.0 GiB	GPU NVIDIA GeForce RTX 4090 • 49140 MiB driver 580.173.02 • 450 W	运行时 Docker 29.1.3 Python 3.12.3
---	--	--	---	---

本机模型容器

部署	来源 / 量化	镜像	内存 / swap 限制	完整启动命令
qwen38 Qwen/Qwen3.8-27B-FP8	Model Scope 28.8 GiB • fp8	vllm/vllm-openai@sha256:d9a5c1c1614c959fde8d2a4d68449db184572528a6055afdd0caf1e66fb51504	16.0 GiB / 16.0 GiB	/models/Qwen3.8-27B-FP8 --host 0.0.0.0 --port 8000 --served-model-name qwen3.8-27b-fp8 --max-model-len 65536 --gpu-memory-utilization 0.92 --cpu-offload-gb 0 --max-num-seqs 4 --max-num-batched-tokens 8192 --reasoning-parser qwen3 --default-chat-template-kwarg {"enable_thinking": false} --enable-auto-tool-choice --tool-call-parser qwen3_coder --limit-mm-per-prompt {"image": 2, "video": 0}
qwen36 Qwen/Qwen3.6-35B-A3B-FP8	Model Scope 34.9 GiB • fp8	vllm/vllm-openai@sha256:d9a5c1c1614c959fde8d2a4d68449db184572528a6055afdd0caf1e66fb51504	16.0 GiB / 16.0 GiB	/models/Qwen3.6-35B-A3B-FP8 --host 0.0.0.0 --port 8000 --served-model-name qwen3.6-35b-a3b-fp8 --max-model-len 32768 --gpu-memory-utilization 0.95 --cpu-offload-gb 0 --max-num-seqs 2 --max-num-batched-tokens 8192 --reasoning-parser qwen3 --default-chat-template-kwarg {"enable_thinking": false} --enable-auto-tool-choice --tool-call-parser qwen3_coder --limit-mm-per-prompt {"image": 2, "video": 0}

外部 DeepSeek endpoint

endpoint	模型	硬件	运行时	冷启动不可用原因
private-dgx-spark	deepseek-v4-flash-0731	2 x NVIDIA GB10 / DGX Spark cluster	vLLM OpenAI-compatible API	service lifecycle and startup logs are not exposed to this benchmark host
online-gateway	deepseek-v4-flash (dynamic alias)	not disclosed	not disclosed behind managed API	provider service lifecycle is not observable

审计与方法边界

评分勘误: `cdc_latest_live` 因 v1 题面未解释 I/U/D 被剔除; `stable_toposort` 按字典插入顺序修正预期并执行异常检查。原始证据不改写, 表内同时保留原始宏平均。

- DeepSeek 每组只完成 n=2; 标准差只描述这两轮观测, 不足以证明稳定性优势。high 是风险保守默认, 不是统计显著结论。
- online 使用官方 `thinking` 与 `reasoning_effort` 请求字段并开启 SSE; private DSpark 使用已验证的 chat-template thinking 开关并传相同 effort。
- online-high-r2 出现 1 个空 final; 错误、空 final 与 length 截断分别统计。
- GB10 private max/384K 的 504 目前是 Nginx read-timeout 的高置信假设, 仍需 NAS 上 `nginx -T`、error log/request-id 及 SSE/non-stream A/B 证实, 不能写成已确认根因。
- 每题在评分后只提交 final/reasoning 前缀、完整字符数和 SHA-256; 评分发生在截断存储之前。
- online 仅提供动态 alias `deepseek-v4-flash`; private 使用固定 `deepseek-v4-flash-0731`。硬件、服务 revision 与网络路径不同。