

Qwen3.8-27B FP8、Unsloth GGUF 与 MTP2 选型

四种配置分维度比较：FP8/vLLM、UD-Q4_K_XL 基线、UD-Q4_K_XL + MTP2、UD-Q6_K_XL。

选择 UD-Q4_K_XL + MTP2

作为 RTX 4090 默认推理配置。在完全相同的模型、65K context、F16 KV、采样和单流请求下，仅启用内置 MTP head，decode 从 46.57 提升到 94.33 tok/s (+102.5%)，E2E 从 23.19 降到 11.99 秒；业务准确率保持 17/18，视觉保持 6/6。

MTP2 比基线多用约 0.95 GiB 显存。Q6 与 FP8 保留为离线回归资产，不长期驻留。

选择门槛

- SQL、Python、故障分析不能出现系统性退化
- 图片识别必须保留
- 禁止 CPU weight offload
- 65K context 下保留至少 4 GiB 显存余量
- 性能收益必须来自同机、同 prompt、同采样条件

94.33 tok/s

MTP2 单流 decode

17 / 18

湖仓 thinking-low

6 / 6

图片识别


22.66 GiB

65K + F16 KV + MTP 空载显存

性能分维度对比

响应时间受到实际生成 token 数影响，不能代替吞吐；因此 decode TPS、E2E、TTFT、完成 token 分列展示。


Decode 吞吐，越高越好




端到端响应时间，越低越好



空载显存，越低越好



服务启动，越低越好



配置	业务	视觉	TPS	TTFT	E2E	输出 token	最终答案	显存	启动	权重
FP8 / vLLM	18/18	6/6	19.79	83 ms	103.6 s	2048	无 (length)	42.42 GiB	198.6 s	30.89 GB
UD-Q4 / llama.cpp	17/18	6/6	46.51	239 ms	23.2 s	1069	有	21.72 GiB	100.9 s	17.92 GB
UD-Q4 + MTP2	17/18	6/6	94.33	208 ms	12.0 s	1111	有	22.66 GiB	20.4 s	17.92 GB
UD-Q6 / llama.cpp	17/18	6/6	34.49	235 ms	28.7 s	981	有	28.75 GiB	181.3 s	25.92 GB

FP8 的三次性能请求均生成 2,048 个 reasoning token 后以 length 结束，final content 为空；三种 llama.cpp 配置均正常 stop 并给出最终答案。MTP2 生成 1,111 token，基线为 1,069 token，因此选型以 TPS、质量和 E2E 联合判断。

短输出交叉验证（max 128）：基线 46.87 tok/s、2.93s；MTP2 77.13 tok/s、1.86s。本机没有复现社区在部分短输出上的退化。

准确率与任务时延

FP8 为 18/18；Q4 基线、Q4 + MTP2 与 Q6 均为 17/18。MTP2 与 Q4 基线失败的是同一个区间合并题；18 题样本只能证明本轮没有系统性退化，不能证明量化或推测解码在统计上等精度。

维度	FP8 / vLLM	UD-Q4 基线	UD-Q4 + MTP2	UD-Q6
复杂 SQL	FP8 / vLLM 6/6, 均值 25.8s	UD-Q4 / llama.cpp 6/6, 均值 14.7s	UD-Q4 + MTP2 6/6, 均值 7.9s	UD-Q6 / llama.cpp 6/6, 均值 17.9s
Python	FP8 / vLLM 6/6, 均值 64.0s	UD-Q4 / llama.cpp 5/6, 均值 29.1s	UD-Q4 + MTP2 5/6, 均值 21.6s	UD-Q6 / llama.cpp 5/6, 均值 44.6s
故障分析	FP8 / vLLM 6/6, 均值 27.3s	UD-Q4 / llama.cpp 6/6, 均值 11.9s	UD-Q4 + MTP2 6/6, 均值 6.6s	UD-Q6 / llama.cpp 6/6, 均值 16.9s

失败项原始结论

FP8 / vLLM	无
UD-Q4 / llama.cpp	merge_intervals_payload: ```python def merge_payload_ranges(items): for start, end, payload in items: if start > end: raise ValueError(f"Invalid range: start ({start}) > end ({end})") sorted_items = sorted(items, key=lambda x: (x[0], x[1])) if not sor
UD-Q4 + MTP2	merge_intervals_payload: ```python def merge_payload_ranges(items): for start, end, payload in items: if start > end: raise ValueError(f"Invalid range: start ({start}) > end ({end})") sorted_items = sorted(items, key=lambda x: (x[0], x[1])) merged = [
UD-Q6 / llama.cpp	schema_drift: ```python def schema_drift(expected, actual): results = [] def collect_leaves(d, prefix): leaves = [] for k, v in d.items(): path = f"{prefix}.{k}" if prefix else k if isinstance(v, dict): leaves

Q4 基线与 MTP2 都将整数区间相邻解释为 touching，使用了 end + 1；Q6 在 schema drift 中额外返回了变更类型，而 oracle 只要求路径。它们是需求解释偏差，不是 CUDA、截断或空回答。

Dynamic GGUF 不是单一位宽

文件	866 个 tensor 的类型分布
UD-Q4_K_XL	F32 360 / IQ4_XS 65 / Q4_K 97 / Q5_K 325 / Q6_K 19
UD-Q6_K_XL	F32 360 / Q5_K 96 / Q6_K 131 / Q8_0 279

API 的概括 ftype 不能代表 Dynamic GGUF 的逐 tensor 配置，选型以文件身份和实际分布为准。

测试环境与方法

固定环境

- GPU：NVIDIA GeForce RTX 4090，49,140 MiB；driver 580.173.02
- FP8：vLLM 0.19.0，65,536 context，CPU offload 0
- 首轮 GGUF：llama.cpp build 10459 / commit 4197155ad
- MTP A/B：官方容器 build 10454 / commit 4df29be4f，同一 OCI digest
- GGUF：65,536 context，parallel 1，F16 KV，Flash Attention，全 GPU layers
- MTP arm 仅增加 draft-mtp、n-max 2、p-min 0
- 模型与 mmproj：ModelScope，revision f1bfb127…，本地 SHA-256 校验
- 采样：temperature 1.0、top_p 0.95、top_k 20、seed 42、reasoning_effort low

测量定义

- 质量：lakehouse-thinking-v2，SQL/Python/故障各 6 题
- 视觉：6 张确定性生成图，严格 exact-match
- 性能：1 次预热 + 3 次单流 SSE 实测
- TTFT：请求发出至首个 reasoning/content delta
- TPS：completion_tokens / (E2E - TTFT)
- 启动：进程或容器 start 至 health-ready；未清 Linux page cache
- MTP 启动 20.43s 来自 warm page-cache，不参与冷启动排名

候选筛选

候选	结论	原因
Unsloth NVFP4	排除	vLLM/LLM Compressor 官方说明 NVFP4 需要 Blackwell compute capability 10.0；RTX 4090 是 Ada 8.9。
GGUF + vLLM	排除	vLLM 官方文档仍将 GGUF 标为 experimental、under-optimized，并要求 OOT plugin。
Dynamic GGUF + llama.cpp	采用	CUDA 支持成熟，Qwen3.8 文本与新视觉 projector 均在固定 commit 上验证。

技术来源：Unsloth Qwen3.8 GGUF 固定 revision • Qwen3.8 MTP 社区 recipe • llama.cpp MTP 实现 • vLLM quantization scheme • vLLM GGUF documentation

部署决策与运行边界

默认服务

- 模型：Qwen3.8-27B-UD-Q4_K_XL.gguf
- API ID：qwen3.8-27b
- 端口：0.0.0.0:8005
- 上下文：65,536；parallel 1；F16 KV
- MTP：draft-mtp；n-max 2；p-min 0
- 资源：全 GPU layers；容器内存上限 48 GiB
- Embedding：BGE-M3 / CPU-only Ollama 保持独立运行

生产建议

- 常规请求默认 non-thinking
- 复杂 SQL/Python/故障分析按请求启用 low
- MTP 是单流优化；并发 2/4 未验收前不增加 parallel
- 监控 GPU headroom，低于 4 GiB 拒绝并发扩容
- 无认证 API 仅限受控 LAN，不直接暴露公网
- 升级 llama.cpp、量化文件或 KV 类型后必须重跑本报告

首轮量化选型使用 llama.cpp b10459 / 4197155ad；MTP 严格 A/B 与最终容器固定为官方 b10454 / 4df29be4。选定 Q4 + MTP2 实测为 **17/18、视觉 6/6、94.33 tok/s、11.99s**。

部署脚本：qwen38-rtx4090-llamacpp/。Q6 与 FP8 不删除，作为离线回归和回滚资产；同一时刻只运行一个 27B 服务。

原始证据身份

文件	SHA-256
deployment-metrics.json	bec8a1a5513612960759e4f3f2fbe37bc6683578da9569d7a3c2e8052d800b63
fp8-performance.json	d3215471803baa1319ea60bf8deba9a3d1e5703162206521d813865e7d779be9
fp8-quality-r1.json	46400e137298bccdf63d110758986bb9490172f68dd4fb6f883cb1960a93a5c2

文件	SHA-256
fp8-vision.json	ce2c707a0012a7dacbd87f8d3f574a0bf042d838b3680bba18266c583b1d1090
q4-baseline-short-performance.json	dd703ce16887a4f4a10c1e5b3ddcc54b42c7dbf2d4e03aa3dbac180834782bd1
q4-deployed-performance.json	e535b1b9a0d329bdf23242053ec001c408af698f663ee3fd67c93f66cc5cddb8
q4-deployed-quality-r1.json	076b23493ab9c8c5c75cda95170c04b4e7e73b84384910918d9e3e1873094b20
q4-deployed-vision.json	6ad2817d05550d34a7405574d3a059b6cf723fe601be8f5f7e2aa097b220734b
q4-mtp2-performance.json	0b3eab4ffdddbba46b604f4d4b7acba263f569e36fe3e46c817b213617286a03
q4-mtp2-quality-r1.json	35f9b3b306f0d283b34a4e4a9a5fd44b953f1c259914d14e96c1bc53ea0fdc38
q4-mtp2-short-performance.json	a055ef96154f7e146c541ef8e21f6178c30f4088b26fe29904c196ed4f5a1bb4
q4-mtp2-vision.json	832f624771f17b9de64579acbeb4b12d8da5afe6474709685c207b8b663cfa81
q4-performance.json	9856aaf502707006eb1b913e0cd7d2e4644517fdca5cd98d707d1c5645b7888b
q4-quality-r1.json	ab4f025109a9b2b687fd521abb99a1d31e38fac6ba60c37fe00a7b61bebb2e1d
q4-vision.json	2c4a824f751e67ab0c62e0cb791ee5c15cf7c81b687f057d4ec14d4297c64f4c
q6-performance.json	5832e59bde57de1cc3c4b4a0c6df3a14fffbf6deec425d40d3e2411a7ff94a08
q6-quality-r1.json	21c2886ea6760bf32aaa10d9934fb2f07a491f758ad42f135e472ec631b72f00
q6-vision.json	7870f60628d1daa683fcd989a2fa03b6785620c7c44499b47ad2108d98ece77d

结论只覆盖本页记录的 RTX 4090、模型 revision、运行时 commit、上下文与采样参数。并发 2/4、160K + Q4 KV 与 48 小时压力测试仍待后续独立验证。