

Qwen3.8-27B FP8、Unsloth GGUF 与 MTP2 选型

四种配置分维度比较：FP8/vLLM、UD-Q4_K_XL 基线、UD-Q4_K_XL + MTP2、UD-Q6_K_XL。

选择 UD-Q4_K_XL + MTP2，默认 256K

作为 RTX 4090 默认推理配置。在完全相同的模型、65K context、F16 KV、采样和单流请求下，仅启用内置 MTP head，decode 从 46.57 提升到 94.33 tok/s (+102.5%)，E2E 从 23.19 降到 11.99 秒；业务准确率保持 17/18，视觉保持 6/6。

生产 context 提升到 262,144：245,034-token 首尾双校验码精确召回，短提示 TPS 比 65K 仅低 0.9%，仍保留 11.58 GiB 显存。128K 是需要与其他 GPU 服务共存时的保守档。

选择门槛

- SQL、Python、故障分析不能出现系统性退化
- 图片识别必须保留
- 禁止 CPU weight offload
- 目标 context 下保留至少 4 GiB 显存余量
- 长上下文必须实际填充并验证首尾召回

93.45 tok/s

256K 档短提示 decode

245,034

已验证输入 tokens

100%

首尾校验码召回


35.79 GiB

256K + F16 KV + MTP 空载显存

性能分维度对比

响应时间受到实际生成 token 数影响，不能代替吞吐；因此 decode TPS、E2E、TTFT、完成 token 分列展示。


Decode 吞吐，越高越好




端到端响应时间，越低越好



空载显存，越低越好



服务启动，越低越好



配置	业务	视觉	TPS	TTFT	E2E	输出 token	最终答案	显存	启动	权重
FP8 / vLLM	18/18	6/6	19.79	83 ms	103.6 s	2048	无 (length)	42.42 GiB	198.6 s	30.89 GB
UD-Q4 / llama.cpp	17/18	6/6	46.51	239 ms	23.2 s	1069	有	21.72 GiB	100.9 s	17.92 GB
UD-Q4 + MTP2	17/18	6/6	94.33	208 ms	12.0 s	1111	有	22.66 GiB	20.4 s	17.92 GB
UD-Q6 / llama.cpp	17/18	6/6	34.49	235 ms	28.7 s	981	有	28.75 GiB	181.3 s	25.92 GB

FP8 的三次性能请求均生成 2,048 个 reasoning token 后以 length 结束，final content 为空；三种 llama.cpp 配置均正常 stop 并给出最终答案。MTP2 生成 1,111 token，基线为 1,069 token，因此选型以 TPS、质量和 E2E 联合判断。

短输出交叉验证（max 128）：基线 46.87 tok/s、2.93s；MTP2 77.13 tok/s、1.86s。本机没有复现社区在部分短输出上的退化。

上下文档位实测

三档都使用同一 Q4 + MTP2、F16 KV、parallel 1。短提示性能为同一 1,111-token 输出的 1 次预热 + 3 次实测；128K/256K 另实际填充长提示，在开头和末尾放置两个确定性校验码。

档位	分配 context	空载显存	显存余量	短提示 TPS	短提示 E2E	长上下文结果
65K	65,536	22.66 GiB	24.70 GiB	94.33	11.99s	本轮未填充
128K	131,072	27.04 GiB	20.33 GiB	94.09	12.02s	120,036 tokens / 68.8s / prefill 1759.7 tok/s / passed
256K	262,144	35.79 GiB	11.58 GiB	93.45	12.10s	245,034 tokens / 195.0s / prefill 1261.6 tok/s / passed

默认：256K

覆盖模型原生 262,144 context；245,034-token 首尾召回通过。适合大型代码库、湖仓元数据和故障资料的单用户分析。

保守：128K

首尾召回同样通过，空载多保留约 8.75 GiB 显存。需要同卡临时运行其他 GPU 任务时切换到该档。

长提示延迟主要来自 prefill：120K 为 68.8s，245K 为 195.0s。256K 能运行不代表每个请求都应填满；客户端应按任务控制实际输入长度。

准确率与任务时延

FP8 为 18/18；Q4 基线、Q4 + MTP2 与 Q6 均为 17/18。MTP2 与 Q4 基线失败的是同一个区间合并题；18 题样本只能证明本轮没有系统性退化，不能证明量化或推测解码在统计上等精度。

维度	FP8 / vLLM	UD-Q4 基线	UD-Q4 + MTP2	UD-Q6
复杂 SQL	FP8 / vLLM 6/6, 均值 25.8s	UD-Q4 / llama.cpp 6/6, 均值 14.7s	UD-Q4 + MTP2 6/6, 均值 7.9s	UD-Q6 / llama.cpp 6/6, 均值 17.9s
Python	FP8 / vLLM 6/6, 均值 64.0s	UD-Q4 / llama.cpp 5/6, 均值 29.1s	UD-Q4 + MTP2 5/6, 均值 21.6s	UD-Q6 / llama.cpp 5/6, 均值 44.6s
故障分析	FP8 / vLLM 6/6, 均值 27.3s	UD-Q4 / llama.cpp 6/6, 均值 11.9s	UD-Q4 + MTP2 6/6, 均值 6.6s	UD-Q6 / llama.cpp 6/6, 均值 16.9s

失败项原始结论

FP8 / vLLM	无
UD-Q4 / llama.cpp	merge_intervals_payload: ```python def merge_payload_ranges(items): for start, end, payload in items: if start > end: raise ValueError(f"Invalid range: start ({start}) > end ({end})") sorted_items = sorted(items, key=lambda x: (x[0], x[1])) if not sor
UD-Q4 + MTP2	merge_intervals_payload: ```python def merge_payload_ranges(items): for start, end, payload in items: if start > end: raise ValueError(f"Invalid range: start ({start}) > end ({end})") sorted_items = sorted(items, key=lambda x: (x[0], x[1])) merged = [
UD-Q6 / llama.cpp	schema_drift: ```python def schema_drift(expected, actual): results = [] def collect_leaves(d, prefix): leaves = [] for k, v in d.items(): path = f"{prefix}.{k}" if prefix else k if isinstance(v, dict): leaves

Q4 基线与 MTP2 都将整数区间相邻解释为 touching，使用了 end + 1；Q6 在 schema drift 中额外返回了变更类型，而 oracle 只要求路径。它们是需求解释偏差，不是 CUDA、截断或空回答。

Dynamic GGUF 不是单一位宽

文件	866 个 tensor 的类型分布
UD-Q4_K_XL	F32 360 / IQ4_XS 65 / Q4_K 97 / Q5_K 325 / Q6_K 19
UD-Q6_K_XL	F32 360 / Q5_K 96 / Q6_K 131 / Q8_0 279

API 的概括 ftype 不能代表 Dynamic GGUF 的逐 tensor 配置，选型以文件身份和实际分布为准。

测试环境与方法

固定环境

- GPU：NVIDIA GeForce RTX 4090，49,140 MiB；driver 580.173.02
- FP8：vLLM 0.19.0，65,536 context，CPU offload 0
- 首轮 GGUF：llama.cpp build 10459 / commit 4197155ad
- MTP A/B：官方容器 build 10454 / commit 4df29be4f，同一 OCI digest
- GGUF：65,536 context，parallel 1，F16 KV，Flash Attention，全 GPU layers
- MTP arm 仅增加 draft-mtp、n-max 2、p-min 0
- 模型与 mmproj：ModelScope，revision f1bfb127…，本地 SHA-256 校验
- 采样：temperature 1.0、top_p 0.95、top_k 20、seed 42、reasoning_effort low

测量定义

- 质量：lakehouse-thinking-v2，SQL/Python/故障各 6 题
- 视觉：6 张确定性生成图，严格 exact-match
- 性能：1 次预热 + 3 次单流 SSE 实测
- TTFT：请求发出至首个 reasoning/content delta
- TPS：completion_tokens / (E2E - TTFT)
- 启动：进程或容器 start 至 health-ready；未清 Linux page cache
- MTP 启动 20.43s 来自 warm page-cache，不参与冷启动排名

候选筛选

候选	结论	原因
Unsloth NVFP4	排除	vLLM/LLM Compressor 官方说明 NVFP4 需要 Blackwell compute capability 10.0；RTX 4090 是 Ada 8.9。
GGUF + vLLM	排除	vLLM 官方文档仍将 GGUF 标为 experimental、under-optimized，并要求 OOT plugin。
Dynamic GGUF + llama.cpp	采用	CUDA 支持成熟，Qwen3.8 文本与新视觉 projector 均在固定 commit 上验证。

技术来源：Unsloth Qwen3.8 GGUF 固定 revision • Qwen3.8 MTP 社区 recipe • llama.cpp MTP 实现 • vLLM quantization scheme • vLLM GGUF documentation

部署决策与运行边界

默认服务

- 模型：Qwen3.8-27B-UD-Q4_K_XL.gguf
- API ID：qwen3.8-27b
- 端口：0.0.0.0:8005
- 上下文：262,144；parallel 1；F16 KV
- MTP：draft-mtp；n-max 2；p-min 0
- 资源：全 GPU layers；容器内存上限 48 GiB
- Embedding：BGE-M3 / CPU-only Ollama 保持独立运行

生产建议

- 常规请求默认 non-thinking
- 复杂 SQL/Python/故障分析按请求启用 low
- MTP 是单流优化；并发 2/4 未验收前不增加 parallel
- 监控 GPU headroom，低于 4 GiB 拒绝并发扩容
- 实际输入按任务裁剪，不因分配 256K 而默认填满
- 无认证 API 仅限受控 LAN，不直接暴露公网

首轮量化选型使用 llama.cpp b10459 / 4197155ad；MTP 严格 A/B 与最终容器固定为官方 b10454 / 4df29be4。65K A/B 为 **17/18、视觉 6/6、94.33 tok/s**；256K 生产档短提示为 **93.45 tok/s、12.10s**，长上下文召回通过。

部署脚本：qwen38-rtx4090-llamacpp/。Q6 与 FP8 不删除，作为离线回归和回滚资产；同一时刻只运行一个 27B 服务。

原始证据身份

文件	SHA-256
deployment-metrics.json	6dcead6ce293e712db3b7094adb73efd6ca8bb84d53112df3b4f80e4ce412f1d
fp8-performance.json	d3215471803baa1319ea60bf8deba9a3d1e5703162206521d813865e7d779be9

文件	SHA-256
fp8-quality-r1.json	46400e137298bccdf63d110758986bb9490172f68dd4fb6f883cb1960a93a5c2
fp8-vision.json	ce2c707a0012a7dacbd87f8d3f574a0bf042d838b3680bba18266c583b1d1090
q4-baseline-short-performance.json	dd703ce16887a4f4a10c1e5b3ddcc54b42c7dbf2d4e03aa3dbac180834782bd1
q4-deployed-performance.json	e535b1b9a0d329bdf23242053ec001c408af698f663ee3fd67c93f66cc5cddb8
q4-deployed-quality-r1.json	076b23493ab9c8c5c75cda95170c04b4e7e73b84384910918d9e3e1873094b20
q4-deployed-vision.json	6ad2817d05550d34a7405574d3a059b6cf723fe601be8f5f7e2aa097b220734b
q4-mtp2-128k-long-context.json	f1ebc562ade8d73e815a31c3799fe97f1e1967c800a817bdbcbe593b42804e98
q4-mtp2-128k-performance.json	d5f20159995b98431bda9bdb43e3f08fd119e27c42fb8a2797bae3b7ed591b6e
q4-mtp2-256k-long-context.json	752b2e339273d469f443ff08b8f246843581438165ae1eb8941def5299fafd05
q4-mtp2-256k-performance.json	61b74f4be13a6ee26336191b4c739c35242b4ba4198adae48a1be29ced883104
q4-mtp2-performance.json	0b3eab4fddddd46b604f4d4b7acba263f569e36fe3e46c817b213617286a03
q4-mtp2-quality-r1.json	35f9b3b306f0d283b34a4e4a9a5fd44b953f1c259914d14e96c1bc53ea0fdc38
q4-mtp2-short-performance.json	a055ef96154f7e146c541ef8e21f6178c30f4088b26fe29904c196ed4f5a1bb4
q4-mtp2-vision.json	832f624771f17b9de64579acbeb4b12d8da5afe6474709685c207b8b663cfa81
q4-performance.json	9856aaf502707006eb1b913e0cd7d2e4644517fdca5cd98d707d1c5645b7888b
q4-quality-r1.json	ab4f025109a9b2b687fd521abb99a1d31e38fac6ba60c37fe00a7b61bebb2e1d
q4-vision.json	2c4a824f751e67ab0c62e0cb791ee5c15cf7c81b687f057d4ec14d4297c64f4c
q6-performance.json	5832e59bde57de1cc3c4b4a0c6df3a14fffbf6deec425d40d3e2411a7ff94a08
q6-quality-r1.json	21c2886ea6760bf32aaa10d9934fb2f07a491f758ad42f135e472ec631b72f00
q6-vision.json	7870f60628d1daa683fcd989a2fa03b6785620c7c44499b47ad2108d98ece77d

结论只覆盖本页记录的 RTX 4090、模型 revision、运行时 commit、上下文与采样参数。并发 2/4、KV 量化替代方案与 48 小时压力测试仍待后续独立验证。